ĐẠI HỌC KINH TẾ QUỐC DÂN

VIỆN ĐÀO TẠO TIÊN TIẾN, CHẤT LƯỢNG CAO VÀ POHE

_____***_____

BÀI TẬP NHÓM HỌC PHẦN KHOA HỌC DỮ LIỆU TRONG KINH TẾ VÀ KINH DOANH

Lớp học phần: TOKT1138(126)CLC_57-Khoa học dữ liệu trong kinh tế và kinh doanh

Giảng viên hướng dẫn: Ts. Trần Đức Minh

Nhóm thực hiện: **1**

Sinh viên thực hiện: Nguyễn Hoàng Tùng – 11240596

Trần Đình Huy Long – 11245900

Vũ Đức Trung – 11247783

Hoàng Tuấn Minh – 11244102

Đỗ Việt Hoàng - 11246044

Hà Nội - 2026

MỤC LỤC BÁO CÁO

GIAI ĐOẠN 1. THU THẬP VÀ ĐÁNH GIÁ DỮ LIỆU BAN ĐẦU 2
1.1. Nguồn dữ liệu và Giới thiệu tập dữ liệu Titanic 3
1.2. Kiểm tra Cấu trúc, Quy mô và Kiểu dữ liệu 3
1.3. Rà soát Giá trị Khuyết thiếu (Missing Values) 4
GIAI ĐOẠN 2. TIỀN XỬ LÝ, LÀM SẠCH VÀ TẠO ĐẶC TRƯNG MỚI 4
2.1. Giải trình Xử lý Khuyết thiếu Cột Age (Median theo Danh xưng) 5
2.2. Xử lý Khuyết thiếu Cột Embarked và Cabin 5
2.3. Tạo Đặc trưng Mới (Feature Engineering) 5
2.4. Mã hóa Biến Phân loại và Chuẩn hóa Dữ liệu (Scaling) 5
GIAI ĐOẠN 3. PHÂN TÍCH KHÁM PHÁ DỮ LIỆU VÀ TRỰC QUAN HÓA 5
3.1. Kiểm định Giả thuyết: Tỷ lệ Sống sót theo Giới tính 6
3.2. Bất bình đẳng Kinh tế - Xã hội theo Hạng vé (Pclass) 6
3.3. Ảnh hưởng của Phân phối Độ tuổi và Yếu tố Gia đình 6
GIAI ĐOẠN 4. HUẤN LUYỆN MÔ HÌNH HỌC MÁY VÀ ĐỀ XẤU GIẢI PHÁP 6
4.1. So sánh Hiệu năng 6 Thuật toán Machine Learning 7
4.2. Tinh chỉnh Ngưỡng Quyết định (Threshold Tuning) 7
4.3. Tóm tắt Phát hiện Chuyên môn và Bài học Kinh doanh 7
4.4. Hạn chế của Tập dữ liệu và Hướng Mở rộng 8
KẾT LUẬN CHUNG 8

GIAI ĐOẠN 1. THU THẬP VÀ ĐÁNH GIÁ DỮ LIỆU BAN ĐẦU

1.1. Nguồn dữ liệu và Giới thiệu tập dữ liệu Titanic

Nhóm lựa chọn tập dữ liệu Titanic (dự đoán khả năng sống sót của hành khách trong thảm họa chìm tàu năm 1912) để thực hiện toàn bộ quy trình thu thập, kiểm tra, tiền xử lý, phân tích khám phá và xây dựng mô hình học máy. Dữ liệu được thu thập trực tiếp từ kho lưu trữ chuẩn với 891 bản ghi quan sát thuộc tập huấn luyện (train set).

Mục tiêu cốt lõi của bài toán là dự đoán biến mục tiêu Survived (0: Tử vong, 1: Sống sót) dựa trên các thuộc tính đặc trưng về nhân khẩu học, điều kiện kinh tế - xã hội và hành trình của hành khách.

1.2. Kiểm tra Cấu trúc, Quy mô và Kiểu dữ liệu

Tập dữ liệu bao gồm 891 quan sát và 12 thuộc tính ban đầu. Cấu trúc và kiểu dữ liệu chi tiết được tổng hợp trong Bảng 1.1:

Bảng 1.1: Danh mục thuộc tính và kiểu dữ liệu ban đầu

Tên Thuộc Tính	Kiểu Dữ Liệu	Mô Tả Chức Năng	Ví Dụ Dữ Liệu
PassengerId	Integer	Mã định danh duy nhất của hành khách	1, 2, 3...
Survived	Integer	Biến mục tiêu (0 = Chết, 1 = Sống)	0, 1
Pclass	Integer	Hạng vé (1 = Hạng Nhất, 2 = Hạng Nhì, 3 = Phổ thông)	1, 2, 3
Name	Object	Họ và tên đầy đủ kèm danh xưng	Braund, Mr. Owen Harris
Sex	Object	Giới tính (male / female)	male, female
Age	Float	Độ tuổi tính theo năm	22.0, 38.0
SibSp	Integer	Số anh chị em / vợ chồng đi cùng	0, 1, 2
Parch	Integer	Số cha mẹ / con cái đi cùng	0, 1, 2
Ticket	Object	Mã số vé chuyến đi	A/5 21171, PC 17599
Fare	Float	Giá vé mua tính theo Bảng Anh (£)	7.25, 71.2833
Cabin	Object	Số phòng / số cabin trên tàu	C85, E46, NaN
Embarked	Object	Cảng lên tàu (C = Cherbourg, Q =	S, C, Q

		Queenstown, S = Southampton)	

1.3. Rà soát Giá trị Khuyết thiếu (Missing Values)

Kết quả kiểm tra dữ liệu khuyết thiếu ban đầu cho thấy 3 thuộc tính gặp tình trạng thiếu dữ liệu ở các mức độ khác nhau:

Bảng 1.2: Thống kê chi tiết giá trị khuyết thiếu ban đầu

Thuộc Tính Khuyết	Số Lượng Thiếu	Tỷ Lệ Khuyết (%)	Đánh Giá & Hướng Xử Lý
Cabin	687	77.10%	Khuyết quá nặng (>75%), không thể phục hồi chính xác -> Loại bỏ cột
Age	177	19.87%	Khuyết trung bình, phân phối lệch -> Điền bằng Trung vị (Median) theo Title
Embarked	2	0.22%	Khuyết rất ít -> Điền bằng Yếu vị (Mode) của dữ liệu

GIAI ĐOẠN 2. TIỀN XỬ LÝ, LÀM SẠCH VÀ TẠO ĐẶC TRƯNG MỚI

2.1. Giải trình Xử lý Khuyết thiếu Cột Age (Median theo Danh xưng)

Giải trình kỹ thuật: Đối với biến Age, nhóm quyết định KHÔNG dùng Mean (giá trị trung bình toàn bộ) hoặc Median tổng quan. Phân phối tuổi của hành khách bị lệch và phụ thuộc chặt chẽ vào vị thế xã hội/danh xưng. Ví dụ, nhóm có danh xưng 'Master' thường là trẻ em nam (tuổi trung bình ~4.57), trong khi 'Mr' là nam giới trưởng thành (tuổi trung vị ~30).

Nhóm tiến hành trích xuất danh xưng (Title) từ cột Name bằng biểu thức chính quy (Regex), gộp các danh xưng hiếm (Capt, Col, Don, Dr, Major, Rev, Sir, Jonkheer, Countess) thành nhóm 'Danh xưng hiếm', quy chuẩn Mlle/Ms -> Miss, Mme -> Mrs. Sau đó, giá trị Age khuyết được điền bằng Median tuổi của chính nhóm Danh xưng tương ứng.

2.2. Xử lý Khuyết thiếu Cột Embarked và Cabin

Đối với Embarked (thiếu 2 dòng): Điền bằng giá trị xuất hiện nhiều nhất (Mode), cụ thể là cảng 'S' (Southampton chiếm >72% lượng khách lên tàu).
Đối với Cabin (thiếu 77.1%): Do tỷ lệ thiếu quá cao, việc tự điền sẽ tạo ra nhiễu lớn. Cột này bị loại bỏ khỏi tập đặc trưng huấn luyện.

2.3. Tạo Đặc trưng Mới (Feature Engineering)

Để tăng cường khả năng phân tách của các mô hình học máy, nhóm thực hiện tạo thêm các biến đại diện cho cấu trúc gia đình:

1. Kích thước gia đình: FamilySize = SibSp + Parch + 1: Tổng số thành viên trong gia đình cùng đi trên chuyến tàu.

2. Trạng thái đi một mình: IsAlone = 1 nếu FamilySize = 1, ngược lại IsAlone = 0: Biến nhị phân đánh giá hành khách đi một mình hay có người thân đi kèm.

2.4. Mã hóa Biến Phân loại và Chuẩn hóa Dữ liệu (Scaling)

Mã hóa nhị phân cột Sex: chuyển female -> 1, male -> 0 (Sex_Code).
Mã hóa One-Hot (get_dummies) cho cột Embarked: tạo các biến giả Cảng_Q, Cảng_S (loại bỏ cột gốc để tránh đa cộng tuyến).
Chuẩn hóa dữ liệu (StandardScaler): Áp dụng chuẩn hóa z-score cho các biến số đối với các thuật toán nhạy cảm với khoảng cách như Logistic Regression, SVM và KNN.

GIAI ĐOẠN 3. PHÂN TÍCH KHÁM PHÁ DỮ LIỆU VÀ TRỰC QUAN HÓA

3.1. Kiểm định Giả thuyết: Tỷ lệ Sống sót theo Giới tính

Giả thuyết đặt ra: Giới tính là yếu tố quyết định hàng đầu đến khả năng sống sót do quy tắc đạo đức cứu hộ hàng hải 'Women and children first' (Phụ nữ và trẻ em trước).

Bảng 3.1: So sánh tỷ lệ sống sót theo Giới tính

Giới Tính	Tổng Số Hành Khách	Số Lượng Sống Sót	Số Lượng Tử Vong	Tỷ Lệ Sống Sót (%)
Nữ (Female)	314	233	81	74.20%
Nam (Male)	577	109	468	18.89%

Diễn giải chuyên sâu (Deep Insight): Tỷ lệ sống sót của nữ giới đạt 74.20%, cao gấp gần 4 lần so với nam giới (18.89%). Điều này minh chứng nguyên tắc ưu tiên cứu hộ đối với phụ nữ đã được thực thi triệt để trong tình huống hoảng loạn khẩn cấp.

3.2. Bất bình đẳng Kinh tế - Xã hội theo Hạng vé (Pclass)

Giả thuyết đặt ra: Địa vị kinh tế - xã hội (thể hiện qua Hạng vé Pclass) ảnh hưởng trực tiếp đến khả năng tiếp cận xuồng cứu sinh.

Bảng 3.2: Thống kê tỷ lệ sống sót theo Hạng vé (Pclass)

Hạng Vé (Pclass)	Tổng Khách	Số Sống Sót	Số Tử Vong	Tỷ Lệ Sống Sót (%)
Hạng 1 (Thượng lưu)	216	136	80	62.96%
Hạng 2 (Trung lưu)	184	87	97	47.28%
Hạng 3 (Bình dân)	491	119	372	24.24%

Diễn giải chuyên sâu: Hành khách Hạng 1 có tỷ lệ sống sót (62.96%) cao gấp hơn 2.5 lần so với Hạng 3 (24.24%). Nguyên nhân cốt lõi xuất phát từ vị trí bố trí cabin: các khoang Hạng 1 nằm ở tầng trên cùng (boong tàu), gần khu vực hạ xuồng cứu sinh, trong khi khoang Hạng 3 nằm dưới đáy tàu, lối đi phức tạp và bị hoảng loạn cản trở khi sự cố xảy ra.

3.3. Ảnh hưởng của Phân phối Độ tuổi và Yếu tố Gia đình

Kết quả phân tích phân phối độ tuổi cho thấy trẻ em (đặc biệt dưới 5 tuổi) có mật độ sống sót cao rõ rệt. Đồng thời, hành khách đi theo gia đình nhỏ (2-4 người) có tỷ lệ sống cao hơn hẳn nhóm đi một mình (IsAlone = 1: 30.35% vs Có gia đình: 50.56%). Sự hỗ trợ lẫn nhau giữa các thành viên gia đình trong lúc di chuyển cứu hộ đóng vai trò rất quan trọng.

GIAI ĐOẠN 4. HUẤN LUYỆN MÔ HÌNH HỌC MÁY VÀ ĐỀ XẤU GIẢI PHÁP

4.1. So sánh Hiệu năng 6 Thuật toán Machine Learning

Nhóm tiến hành phân chia dữ liệu Train (80%) / Test (20%) có phân tầng (stratify=y) và thử nghiệm 6 thuật toán phân loại khác nhau. Kết quả đánh giá trên tập Test được trình bày trong Bảng 4.1:

Bảng 4.1: Bảng so sánh hiệu năng 6 thuật toán Machine Learning

Thuật Toán ML	Accuracy	Precision	Recall	F1-Score
Random Forest	82.12%	81.54%	71.62%	76.26%
Gradient Boosting	81.56%	80.30%	71.62%	75.71%
Support Vector Machine (SVM)	80.45%	78.79%	70.27%	74.29%
Logistic Regression	79.89%	77.61%	70.27%	73.76%
Decision Tree	78.77%	75.71%	71.62%	73.61%
K-Nearest Neighbors (KNN)	77.65%	74.29%	70.27%	72.22%

Đánh giá: Mô hình Random Forest đạt hiệu năng tổng thể cao nhất với Accuracy 82.12% và F1-Score 76.26%, cho thấy tính ổn định vượt trội của phương pháp Ensemble so với các mô hình đơn lẻ.

4.2. Tinh chỉnh Ngưỡng Quyết định (Threshold Tuning)

Thay vì sử dụng ngưỡng mặc định 0.5, nhóm thử nghiệm điều chỉnh ngưỡng dự đoán xác suất đối với Random Forest để tối ưu Recall (tránh bỏ sót nạn nhân):

Bảng 4.2: Kết quả tinh chỉnh ngưỡng quyết định (Threshold Tuning)

Ngưỡng (Threshold)	Accuracy	Precision	Recall	F1-Score
0.30	77.09%	68.89%	83.78%	75.61%
0.40	81.01%	75.32%	79.73%	77.46%
0.45 (Tối ưu)	82.68%	78.95%	78.38%	78.66%
0.50 (Mặc định)	82.12%	81.54%	71.62%	76.26%
0.60	81.01%	84.75%	67.57%	75.19%
0.70	76.54%	87.50%	56.76%	68.85%

Nhận xét: Chọn ngưỡng 0.45 giúp cân bằng tối ưu giữa Precision (78.95%) và Recall (78.38%), đưa chỉ số F1-Score đạt mức cực đại 78.66% và Accuracy tăng lên 82.68%.

4.3. Tóm tắt Phát hiện Chuyên môn và Bài học Kinh doanh

- 3 yếu tố quyết định sống còn: Giới tính (Sex), Hạng vé (Pclass) và Kích thước gia đình (FamilySize).
- Mô hình Ensemble (Random Forest, Gradient Boosting) thể hiện sự ổn định cao nhất trên dữ liệu nhiễu.
- Tinh chỉnh ngưỡng phân loại là bước quan trọng đối với các bài toán sơ tán/cứu hộ khẩn cấp.

4.4. Hạn chế của Tập dữ liệu và Hướng Mở rộng

Hạn chế: Cột Cabin bị thiếu quá nhiều (>77%); dung lượng mẫu tương đối nhỏ (891 bản ghi); thiếu dữ liệu về vị trí chính xác của từng hành khách lúc xảy ra va chạm.
Hướng mở rộng: Kết hợp mô hình Deep Learning (MLP); khai thác thêm thông tin số vé (Ticket) để phát hiện nhóm khách đi chung không cùng họ.

KẾT LUẬN CHUNG

Nhìn lại toàn bộ hành trình phân tích dữ liệu Titanic, bài toán đặt ra không đơn thuần là những con số thống kê khô khan hay các dòng mã lệnh máy học vô tri, mà ẩn sau đó là những lát cắt chân thực về xã hội loài người, sự bất bình đẳng và bản năng sinh tồn.

Qua 4 giai đoạn nghiên cứu được thực hiện bài bản và cẩn trọng – từ bóc tách, làm sạch dữ liệu, kiểm định giả thuyết cho đến tối ưu hóa các thuật toán phân loại (với mô hình Random Forest đạt F1-Score tối ưu 78.66%) – nhóm đã làm rõ những yếu tố cốt lõi chi phối khả năng sinh tồn: từ giới tính, vị thế kinh tế (*hạng vé Pclass*) cho đến cấu trúc gia đình.